

Análisis del Desempeño de Modelos de Aprendizaje Profundo para la Lectura de Labios en Español de México

Alvarado Aguilar Jesús Antonio ¹, Espinosa Cruz Emilio Jared ², Rosas Hernández Pablo Fernando ³,

Dr. Valdez Rodríguez José Eduardo, Dr. Juárez Gambino Joel Omar

Email: ¹jalvaradoa1900@alumno.ipn.mx, ²eespinosac1700@alumno.ipn.mx, ³prosash1600@alumno.ipn.mx

Abstract—Este artículo presenta un análisis del desempeño de varios modelos de aprendizaje profundo aplicados a la tarea de lectura de labios en español de México. Los modelos fueron entrenados para interpretar movimientos labiales correspondientes a letras, sílabas y fonemas del español, utilizando técnicas avanzadas de visión por computadora y redes neuronales. Los resultados son evaluados mediante métricas cuantitativas específicas de precisión y exactitud.

Index Terms—Lectura de Labios, Aprendizaje Profundo, Inteligencia Artificial, Visión por Computadora.

I. INTRODUCCIÓN

La lectura de labios, definida como la interpretación visual de los movimientos labiales para entender el habla, ha ganado relevancia en áreas como la accesibilidad para personas con pérdida auditiva y en aplicaciones de comunicación en entornos sin audio. Aunque se han logrado avances significativos en el reconocimiento de patrones de lectura de labios en inglés, el español de México plantea desafíos únicos debido a su diversidad fonética y variabilidad en pronunciación. Hasta la fecha, existe una carencia de conjuntos de datos (datasets) específicos y modelos optimizados para este idioma, lo cual limita el desarrollo de tecnologías avanzadas de lectura de labios en español.

Este trabajo tiene como objetivo evaluar el rendimiento de diferentes arquitecturas de redes neuronales profundas en la interpretación de movimientos labiales, con un enfoque específico en el español de México. Para ello, se han seleccionado y entrenado modelos como Redes Neuronales Convolucionales Tridimensionales (CNN 3D) y combinaciones de CNN con redes neuronales recurrentes de largo plazo, como las Redes Convolucionales Recurrentes de Largo Plazo (LRCN). La evaluación de los modelos se realizó utilizando un conjunto de datos propio de grabaciones de hablantes nativos, capturando una amplia gama de fonemas correspondientes a letras y sílabas, y contextos de pronunciación característicos del español mexicano. Las arquitecturas fueron evaluadas mediante métricas cuantitativas como precisión, recall y F1 score, proporcionando una medida objetiva de su capacidad para interpretar correctamente los movimientos labiales en este idioma.

Con esta investigación, se pretende ofrecer una contribución significativa al avance de la lectura de labios en español mediante el análisis del desempeño de cada arquitectura, evidenciando sus fortalezas y limitaciones. Los resultados obtenidos permiten vislumbrar las áreas de mejora y los ajustes necesarios en los modelos, lo cual es fundamental

para el desarrollo de tecnologías de accesibilidad y para la investigación en procesamiento de señales visuales en contextos lingüísticos específicos.

II. METODOLOGÍA

Para llevar a cabo el análisis del desempeño de modelos de aprendizaje profundo en la lectura de labios en español de México, se siguió un proceso estructurado que incluyó la **creación del dataset**, el **preprocesamiento del dataset**, la **selección y configuración de modelos de red neuronal** y la **evaluación de cada modelo**.

A. Creación del dataset

Dado que no existen datasets públicos adecuados para la lectura de labios en español de México, se procedió a la creación de un dataset propio. Este conjunto de datos consta de grabaciones de hablantes nativos pronunciando letras y sílabas en español.

Para construir un dataset adecuado, se consideraron los aspectos básicos de la producción del habla, incluyendo la respiración, articulación y fonación, los cuales intervienen en la generación de los fonemas, que son las unidades mínimas de sonido. La articulación, en particular, se centra en los movimientos y posiciones de órganos como la lengua, labios, y mandíbula, que contribuyen a la producción de sonidos [1] [2].

Dado el objetivo de evaluar el desempeño de modelos de aprendizaje profundo para lectura de labios en español, el dataset se organizó en cuatro clasificaciones fonéticas: **vocales**, **consonantes por punto de articulación**, **consonantes por modo de articulación** y **sinfonos**, lo que permite evaluar la capacidad de los modelos en identificar los diferentes sonidos basados en los movimientos labiales específicos de cada tipo de fonema.

- 1) **Vocales**: Se incluyen las cinco vocales del español (**A**, **E**, **I**, **O**, **U**), permitiendo evaluar el reconocimiento de vocales individuales según los movimientos labiales asociados.
- 2) **Consonantes (Punto de Articulación)**: Esta clasificación organiza los fonemas consonánticos en función de la región de contacto en la boca y se incluyen combinaciones de cada consonante con vocales. Las categorías que conforman a esta clasificación son:
 - **Bilabiales**: P, B y M.
 - **Labiodentales**: F y V.
 - **Dentales**: T, D, Z y C.

- **Alveolares:** S, L, N y R.
- **Palatales:** CH, Y, Ñ y LL.
- **Velares:** C/K/Q, J, G y X.

Esta organización permite analizar si el modelo distingue correctamente sonidos según el contacto entre órganos articulatorios [1].

3) **Consonantes (Modo de Articulación):** Clasifica los fonemas de acuerdo a la acción en los órganos que delimitan el flujo de aire. Las categorías que conforman a esta clasificación son:

- **Oclusivos:** P, T y C/K/Q.
- **Fricativos:** F, V, B, Z, C, S, Y, J y G.
- **Nasales:** M, N y Ñ.
- **Vibrantes:** R.
- **Africadas:** CH y X.
- **Laterales:** L y LL.

Este enfoque permite evaluar la capacidad del modelo en identificar cómo se modifica el flujo de aire en cada sonido.

4) **Sinfones:** Esta última clasificación agrupa combinaciones de dos fonemas consonánticos, lo cual añade complejidad en la identificación al tratarse de sonidos compuestos. Las categorías se basan en las características de cada fonema según su punto de articulación y su distribución dentro de este conjunto de datos es la siguiente:

- **Labio-lingualalveolar:** PL, BL, PR y BR.
- **Labiodental-lingualalveolar:** FL y FR.
- **Dentolingual-alveolar:** TL, TR y DR.
- **Linguovelar-alveolar:** CL, GL, CR y GR.

Cada modelo se entrena con muestras de cada una de estas clases, incluyendo combinaciones de fonemas consonánticos y vocales, lo cual proporciona una base sólida para medir el desempeño en distintos tipos de movimientos labiales que corresponden a las diversas categorías fonéticas del español.

B. Preprocesamiento del dataset

Una vez terminada la creación y recopilación de todos los videos que conforman el conjunto de datos, se realizó un preprocesamiento de la información. Los procesos realizados se describen a continuación.

1) **Redimensión de los videos:** Consiste en recortar cada video a una relación y tamaño específico. Para este caso se utiliza un formato cuadrado (1:1), como se muestra en la Figura 1.



Fig. 1: Imagen ilustrativa sobre la redimensión de un video. Elaboración propia.

2) **Recorte de la zona de interés:** Consiste en seleccionar manualmente un área específica del video. Para este trabajo, la zona de interés son los labios, por lo que se seleccionará esta área y sus alrededores, tal como se puede apreciar en la Figura 2.




Fig. 2: Imagen ilustrativa del recorte de la zona de interés. Elaboración propia.

3) **Obtención de los fotogramas:** Implica extraer la secuencia de imágenes que conforman cada segmento de video, tal como se muestra en la Figura 3.




Fig. 3: Imagen ilustrativa sobre la obtención de fotogramas. Elaboración propia.

De cada grabación se extrajeron frames que capturan los movimientos labiales en distintos fonemas y combinaciones silábicas, conformando así un conjunto de datos que representa de manera fiel la pronunciación característica de este idioma.

Cada muestra fue organizada en una estructura jerárquica que permite un etiquetado preciso de cada fonema o sílaba.

La distribución final de cada categoría en subconjuntos de entrenamiento, validación y prueba, se representa en las tablas I, II, III y IV. Con el fin de estandarizar el conjunto de datos final, cada muestra equivale a una secuencia de 18 imágenes, las cuales corresponden a los frames de cada segmento de video.

C. Selección y configuración de modelos de aprendizaje profundo

Para la evaluación del rendimiento en la interpretación de movimientos labiales, se seleccionaron dos tipos de arquitecturas de redes neuronales profundas:

1) **Redes Convolucionales Tridimensionales (CNN 3D):**

Estas redes permiten capturar tanto la dimensión espacial de los movimientos labiales en cada frame como la temporal entre secuencias, siendo adecuadas para el análisis de secuencias de video. Para este tipo de

Clase	Entrenamiento	Validación	Prueba
A	51	9	9
E	51	9	9
I	51	9	9
O	51	9	9
U	51	9	9
Total	255	45	45

TABLE I: Distribución de muestras por clase para la categoría vocales.

Clase	Entrenamiento	Validación	Prueba
Alveolar	1000	180	180
Bilabial	750	135	135
Dental	600	108	108
Labiodental	250	45	45
Palatal	750	135	135
Velar	900	162	162
Total	4250	765	765

TABLE II: Distribución de muestras por clase para la categoría punto de articulación.

Clase	Entrenamiento	Validación	Prueba
Africadas	250	45	45
Fricativos	1850	333	333
Laterales	250	45	45
Nasales	750	135	135
Oclusivos	900	162	162
Vibrantes	250	45	45
Total	4250	765	765

TABLE III: Distribución de muestras por clase para la categoría modo de articulación.

arquitectura se han implementado tres configuraciones diferentes:

- CNN 3D.** Conformada por capas 3D conv, capas de MaxPooling 3D, una capa Flatten, dos capas Densas de 500 unidades con función de activación ReLU y una capa de salida con función de activación Softmax.
- CNN 3D Híbrida.** Conformada por capas 3D conv, capas de MaxPooling 3D en las dos últimas capas 3D conv, capas 2D conv, una capa Flatten, dos

Clase	Entrenamiento	Validación	Prueba
Labio-linguoalveolar	750	135	135
Labiodental-linguoalveolar	1000	180	180
Dentolingual-alveolar	500	90	90
Linguovelar-alveolar	1000	180	180
Total	3250	585	585

TABLE IV: Distribución de muestras por clase para la categoría sinfonos.




Fig. 4: Arquitectura del modelo CNN 3D. Elaboración propia.

capas Densas de 500 unidades con función de activación ReLU y una capa de salida con función de activación Softmax.




Fig. 5: Arquitectura del modelo CNN 3D Híbrida. Elaboración propia.

- CNN 3D Híbrida Mini.** Conformada por capas 3D conv, capas de MaxPooling 3D en cada capa 3D conv, capas 2D conv, una capa Flatten, dos capas Densas de 500 unidades con función de activación ReLU y una capa de salida con función de activación Softmax.

- Redes Convolucionales Recurrentes de Largo Plazo (LRCN):** Estas arquitecturas combinan redes convolucionales para el procesamiento de características espaciales con redes recurrentes para capturar la secuencia temporal de los movimientos, permitiendo una interpretación más compleja de patrones en series temporales. Para este tipo de arquitectura se han implementado dos




Fig. 6: Arquitectura del modelo CNN 3D Híbrida Mini. Elaboración propia.

configuraciones diferentes, las cuales retoman dos de las redes convolucionales 3D:

- a) **LCRN 1.** Inspirada en el modelo de la CNN 3D y agrega un módulo de una red LSTM.




Fig. 7: Arquitectura del modelo LCRN 1. Elaboración propia.

- b) **LCRN 2.** Inspirada en el modelo de la CNN Híbrida y agrega un módulo de una red LSTM.




Fig. 8: Arquitectura del modelo LCRN 2. Elaboración propia.

Cada modelo fue entrenado con el dataset previamente descrito, utilizando técnicas de regularización y ajustes de hiperparámetros específicos para maximizar su capacidad de generalización en el contexto del español de México.

D. Métricas de evaluación

Para evaluar el desempeño de cada modelo, se emplearon las siguientes métricas:

- **Accuracy:** Indica la proporción de predicciones correctas realizadas por el modelo, tanto positivas como negativas, en relación con el total de predicciones [3].
- **Precisión (Precision):** Calcula la proporción de verdaderos positivos frente al total de predicciones positivas, permitiendo medir la exactitud de las predicciones del modelo [3].
- **Recall:** Evalúa la capacidad del modelo para identificar correctamente todas las instancias positivas reales [3].
- **F1 Score:** Es la media armónica entre precisión y recall, proporcionando una medida equilibrada de ambos indicadores.
- **Matriz de confusión:** La matriz de confusión es una tabla que se utiliza frecuentemente para describir el desempeño de un modelo de clasificación sobre un conjunto de

datos de prueba cuyos valores verdaderos son conocidos. Permite visualizar el rendimiento del algoritmo mostrando la distribución de las predicciones correctas e incorrectas, con los verdaderos y falsos positivos y negativos [4].

E. Entorno de entrenamiento

Los entrenamientos de los modelos se llevaron a cabo en la plataforma Lightning AI [5], empleando una GPU Nvidia L4 Tensor Core. Esta tarjeta gráfica, diseñada específicamente para cargas de trabajo de aprendizaje profundo, cuenta con una memoria VRAM de 24 GB y una potencia de cómputo de hasta 30 teraflops para operaciones de precisión simple, optimizando así el rendimiento en el entrenamiento de modelos con redes neuronales profundas. La disponibilidad de estos recursos permitió reducir significativamente los tiempos de procesamiento y mejorar la eficiencia en el ajuste y evaluación de cada modelo.

III. RESULTADOS Y ANÁLISIS

A. Resultados de los entrenamientos

Los modelos fueron evaluados en el conjunto de validación, obteniendo los siguientes resultados en términos de accuracy (TABLE V), precision (TABLE VI), recall (TABLE VII) y F1 score (TABLE VIII):

Modelo	Vocales	Punto	Modo	Sifones
CNN 3D	0.71	0.67	0.57	0.82
CNN 3D híbrida	0.64	0.47	0.58	0.81
Híbrida mini	0.73	0.62	0.47	0.81
LCRN 1	0.76	0.74	0.64	0.88
LCRN 2	0.64	0.64	0.58	0.85

TABLE V: Comparación de **Accuracy** entre modelos para cada categoría

Modelo	Vocales	Punto	Modo	Sifones
CNN 3D	0.70	0.68	0.53	0.81
CNN 3D híbrida	0.62	0.50	0.60	0.82
Híbrida mini	0.72	0.63	0.50	0.81
LCRN 1	0.76	0.74	0.63	0.87
LCRN 2	0.63	0.63	0.45	0.84

TABLE VI: Comparación de **Precision** entre modelos para cada categoría.

En los resultados obtenidos, el modelo **LCRN 1** destaca como el mejor en todas las métricas y categorías evaluadas, lo cual indica que este modelo no solo logra identificar correctamente las instancias positivas, sino que también mantiene un buen equilibrio entre precisión y recall, siendo el modelo más efectivo para este conjunto de datos en general.

Modelo	Vocales	Punto	Modo	Sifones
CNN 3D	0.71	0.66	0.50	0.79
CNN 3D híbrida	0.64	0.44	0.56	0.81
Híbrida mini	0.73	0.61	0.45	0.81
LCRN 1	0.76	0.76	0.61	0.88
LCRN 2	0.64	0.63	0.44	0.84

TABLE VII: Comparación de **Recall** entre modelos para cada categoría.

Modelo	Vocales	Punto	Modo	Sifones
CNN 3D	0.69	0.67	0.51	0.80
CNN 3D híbrida	0.62	0.44	0.57	0.81
Híbrida mini	0.72	0.62	0.45	0.81
LCRN 1	0.76	0.74	0.64	0.88
LCRN 2	0.63	0.63	0.58	0.85

TABLE VIII: Comparación de **F1 Score** entre modelos para cada categoría.

Además de las métricas cuantitativas como precisión, recall y F1 score, se utilizaron matrices de confusión para identificar patrones de error en la clasificación. En la categoría de vocales, las matrices muestran que todos los modelos presentan confusión entre las clases 'E' e 'I', lo cual sugiere una dificultad común para diferenciar estas letras debido a similitudes en los movimientos labiales. Por otro lado, en la categoría de Modo de Articulación, se observa un fuerte desbalanceo de clases, con la mayoría de las muestras concentradas en la clase 'Fricativos'. Sin embargo, este desbalance no impide que los modelos logren identificar y clasificar las demás clases dentro de esta categoría, lo que demuestra una capacidad de generalización adecuada.

B. Análisis de los resultados

El desempeño de los modelos en las distintas categorías de clasificación (vocales, modo y punto de articulación, y sinfones) demostró que las arquitecturas más simples tienden a ser más efectivas, debido a su capacidad para extraer características representativas clave. A continuación, se destacan los resultados más relevantes.

a) *Vocales*: Los modelos LRCN v1, CNN Híbrida Mini y CNN 3D lograron mejores desempeños en esta categoría, con el modelo LRCN v1 destacando por su capacidad de retener características esenciales (1,152 características). En contraste, modelos más complejos, como LRCN v2 y CNN Híbrida, presentaron menor precisión, lo que sugiere que el exceso de características dificulta el enfoque en los detalles críticos. Las vocales A, O y U obtuvieron los mejores resultados, mientras que E e I mostraron menor precisión en las predicciones.

b) *Modo de articulación*: En la categoría de punto de articulación, los modelos demostraron un desempeño sólido,




Fig. 9: Comparación de **Accuracy** entre modelos para cada categoría. Elaboración propia.

destacándose en clases como "Bilabial" y "Velar", donde la precisión y el recall alcanzaron valores altos gracias a las diferencias marcadas en los movimientos labiales asociados. Sin embargo, las clases "Interdental" y "Alveolar" resultaron más desafiantes, debido a la similitud en sus patrones articulatorios, lo que provocó confusiones entre estas categorías.

c) *Punto de articulación*: En la categoría de modo de articulación, se observó un desbalance significativo en las clases, ya que la mayoría de las muestras pertenecían a la clase "Fricativos". Esto representó un reto para los modelos, pero, a pesar de este desbalance, lograron identificar y clasificar correctamente entre las demás clases, como "Oclusivos" y "Nasales". Los resultados indican que la robustez de las arquitecturas permitió mantener un desempeño competitivo en todas las métricas, incluso en escenarios con una distribución desigual de datos.

d) *Sinfones*: El modelo LRCN v1 sobresalió con un 90% de precisión general, destacando en la clase Labiodental-lingual-alveolar (F1-score superior a 0.90). Aunque otros modelos también mostraron resultados competitivos, como el CNN 3D y el LRCN v2, las clases Labio-lingual-alveolar y Dentolingual-alveolar fueron las más desafiantes para todos los modelos.

IV. CONCLUSIONES

El presente trabajo exploró el desempeño de diferentes modelos de aprendizaje profundo para la lectura de labios en español de México, utilizando un dataset especialmente diseñado y categorizado en vocales, consonantes (punto y modo de articulación) y sinfones. Los resultados obtenidos permiten extraer conclusiones relevantes tanto en el ámbito técnico como en el contexto lingüístico.

Los modelos CNN-LSTM, especialmente la versión 1, sobresalieron en casi todas las métricas evaluadas, destacándose su capacidad para manejar tareas complejas como la clasificación en la categoría de Sinfones, donde logró la mayor precisión y recall. Este resultado resalta la ventaja de integrar características espaciales y temporales en tareas relacionadas con la lectura de labios. Por otro lado, los modelos basados exclusivamente

en CNN presentaron un desempeño competitivo en categorías menos complejas, como Vocales, pero mostraron limitaciones en tareas que demandan análisis más sofisticados, como Punto y Modo de Articulación.

En cuanto a las categorías, los resultados indican que la clasificación de Vocales es relativamente más accesible para los modelos, aunque persisten confusiones entre las clases "E" e "I". En la categoría de Punto de Articulación, se identificaron desafíos específicos en clases con características fonéticas similares, como "Dental" y "Alveolar". En el Modo de Articulación, el desbalance de datos en la clase "Fricativos" no impidió que los modelos lograran distinguir entre las demás clases, lo que refleja su capacidad para adaptarse a distribuciones de datos desiguales. Finalmente, la categoría de Sinfones subrayó la efectividad de los modelos en identificar combinaciones fonéticas complejas, aunque se mantiene como un área de oportunidad para mejorar el desempeño general.

Estos hallazgos son significativos para el desarrollo de tecnologías de reconocimiento de habla basadas en lectura de labios, particularmente en lenguas con estructuras fonéticas complejas como el español. Asimismo, la creación del dataset y las pruebas realizadas establecen una base para futuros trabajos en esta área, con la posibilidad de explorar técnicas de aumento de datos más avanzadas o arquitecturas híbridas más sofisticadas.

En síntesis, este trabajo contribuye al avance del campo de la lectura de labios, ofreciendo análisis detallados del desempeño de modelos de aprendizaje profundo y abriendo nuevas perspectivas para el desarrollo de sistemas de apoyo en la comunicación.

V. RECONOCIMIENTOS

Los autores agradecen a la Escuela Superior de Cómputo del Instituto Politécnico Nacional por el apoyo recibido y las facilidades otorgadas para el desarrollo del presente trabajo terminal.

REFERENCES

- [1] S. Mura, *La dinámica articulatoria*. Corpus Editorial y Distribuidora, 2009.
- [2] F. S. Chavez, O. H. Condori, and A. D. Chocano, "Adquisición Fonética-Fonológica," *Instituto Psicopedagógico EOS Perú*, 2013.
- [3] T. Tigerschild, "What is Accuracy, Precision, Recall and F1 Score?" [Online] Available: <https://www.labeled.ai/blog/what-is-accuracy-precision-recall-and-f1-score> [Último acceso: 3 noviembre 2024].
- [4] S. M. W. II, "F-Score: What are accuracy, precision, recall, and F1 score?" [Online] Available: <https://klu.ai/glossary/accuracy-precision-recall-f1> [Último acceso: 3 noviembre 2024].
- [5] "Lightning AI — Turn ideas into AI, Lightning fast," [En línea] Available at: <https://lightning.ai/about> [Último acceso: 4 abril 2024].